



Manual Técnico de Arquitetura, Engenharia e Operação: Tutor de Enfermagem

Este documento constitui o memorial descritivo e manual técnico completo do **Tutor de Enfermagem**, um assistente virtual de inteligência artificial generativa educacional especializado em **Enfermagem Perioperatória** desenvolvido para a Universidade Federal de Santa Catarina (UFSC).

1. Fundamentação Pedagógica e Diretrizes Éticas

O desenvolvimento do Tutor de Enfermagem não visa a substituição do corpo docente ou a automatização de tarefas intelectuais dos alunos, mas sim a criação de um mediador de aprendizagem ativa.

A. O Método Socrático na Enfermagem

Na prática clínica da enfermagem, a tomada de decisão sob pressão exige raciocínio diagnóstico rápido e preciso. O método socrático (maiêutica) funciona por meio de perguntas indutivas que forcem o estudante a:

- * Identificar lacunas em seu próprio conhecimento.
- * Relacionar a teoria fisiopatológica com sinais clínicos observados.
- * Formular hipóteses diagnósticas com base em evidências científicas.
- * Desenvolver autonomia intelectual em vez de memorizar respostas prontas.

O Tutor implementa essa técnica limitando-se a fazer **uma pergunta reflexiva de cada vez** e guiando o aluno na correção de seus próprios erros.

B. Diretrizes da UNESCO e do MEC

O Tutor está alinhado com a recomendação da **UNESCO** sobre a Ética da Inteligência Artificial (2021) e as diretrizes do **MEC** (Ministério da Educação do Brasil) para o uso de tecnologias digitais de informação e comunicação (TDICs):

* **Transparência Acadêmica:** O sistema deixa claro para o estudante que se trata de um assistente de IA.

* **Privacidade dos Dados:** O histórico de conversas é criptografado e persistido de forma segura no Supabase, indexado apenas por um identificador anônimo de sessão.

* **Combate ao Plágio:** A IA é instruída a recusar pedidos de elaboração direta de trabalhos acadêmicos ou respostas diretas a avaliações, atuando estritamente como um facilitador de estudos.

2. Especificação Detalhada das Funções do Aplicativo

O comportamento do Tutor é baseado em quatro fluxos de estudo principais, selecionados a partir do Menu Principal.

A. Opção 1: Resumo de Conteúdo

1. **Delimitação de Tema:** Caso o aluno solicite um tema genérico (ex: "*Quero estudar Anestesia*"), o Tutor aplica um questionamento socrático para ajudá-lo a delimitar o escopo (ex: "*Dentre os tipos de anestesia, você prefere focar em Anestesia Geral ou Regional?*").
1. **Estruturação do Resumo:** Uma vez definido o tema, a IA recupera o conteúdo da base vetorial e constrói um resumo estruturado contendo:
 - **Explicação Técnica:** Conceitos científicos baseados na literatura, acompanhados de citações numéricas.
 - **Exemplo Clínico:** Um caso clínico simulado onde o conceito é aplicado na prática perioperatória.
 - **Relação com a Prática:** Impacto direto na assistência de enfermagem.
 - **Referências Bibliográficas:** Lista dos artigos ou livros de onde os dados foram extraídos.
1. **Questionamento Sequencial:** O Tutor gera **3 perguntas socráticas** personalizadas para avaliar a compreensão do aluno. O sistema faz a primeira pergunta e bloqueia o envio de novas perguntas até que o aluno responda a

ela. A IA avalia a resposta do aluno e, apenas quando este demonstra entendimento, apresenta a segunda pergunta, e assim sucessivamente.

B. Opção 2: Simulado de Prova

1. **Geração do Simulado:** A IA gera um bloco contendo exatamente **5 questões** (3 de múltipla escolha com 4 alternativas e 2 discursivas curtas) baseadas no tema escolhido. O gabarito não é exibido inicialmente.

1. Fluxo de Correção Socrática:

- O aluno envia as suas respostas.
- Para cada questão incorreta, a IA **não fornece a resposta certa**. Em vez disso, ela aponta o erro por meio de uma pista reflexiva (ex: *"Na questão 2, você considerou a hipotermia benéfica na SRPA. Lembre-se dos efeitos do frio sobre a coagulação sanguínea. O que ocorre com as plaquetas sob baixas temperaturas?"*).
- O aluno tem até **3 tentativas** para corrigir cada resposta incorreta.
- Se o aluno falhar nas 3 tentativas, o Tutor exibe a explicação técnica detalhada e o gabarito oficial daquela questão.

C. Opção 3: Informações do Curso

* O Tutor responde a perguntas organizacionais sobre a disciplina (critérios de aprovação, peso das avaliações, cálculo de média, frequência mínima, bibliografia recomendada e datas importantes). Estas informações são extraídas de arquivos administrativos (como o plano de ensino da UFSC) carregados no RAG.

D. Opção 4: Encerrar Sessão

* A IA encerra a interação com uma mensagem de incentivo acadêmico padrão e limpa a sessão ativa no frontend.

3. Arquitetura de Software e Stack Tecnológica

O sistema utiliza uma arquitetura puramente serverless de alta performance, minimizando latências e custos operacionais.

* **Interface Visual (Next.js 15 + React 19 + TailwindCSS 4):**

- Interface responsiva com foco em dispositivos móveis (iOS/Android).

- Design system customizado baseado na paleta **Azul Médico** (primário em azul royal e secundário em azul escuro, com fundos claros em azul suave).
- Transmissão de respostas em tempo real (streaming), reduzindo a latência de carregamento para o usuário.
- Alternador de temas (Claro/Escuro) integrado com salvamento persistente na memória do navegador para evitar oscilações de luz ao recarregar.

* **Processamento do Servidor (Next.js API Routes):**

- Rota de chat unificada que elimina a necessidade de servidores de backend adicionais.
- Configuração de tempo de execução expandido para garantir que o fluxo completo de busca e classificação de dados ocorra sem interrupções.

* **Banco de Dados (Supabase + pgvector):**

- **Tabela de Documentos:** Armazena os blocos de textos dos livros de enfermagem, suas referências de origem, o identificador de similaridade e uma assinatura única do texto (hash) para evitar repetições.
- **Tabela de Histórico:** Salva as interações da conversa por sessão, permitindo que a IA lembre do contexto da conversa atual do estudante.

* **Modelos de Linguagem (Google Gemini API):**

- **Modelo de Tradução Semântica:** Transforma as palavras dos textos e das perguntas em coordenadas matemáticas para busca de significado.
- **Modelo de Geração:** Utiliza a inteligência do Gemini para avaliar a relevância do material e redigir a resposta pedagógica final de forma rápida.

4. Engenharia de RAG e Pipeline de Ingestão de Dados

O pipeline de RAG (Geração Aumentada por Recuperação) do Tutor foi projetado para processar volumes massivos de textos acadêmicos de forma autônoma e eficiente.

A. O Papel do Docling e a Conversão de PDF para Markdown Estruturado

A extração de informações de documentos acadêmicos e manuais técnicos enfrenta um grande obstáculo: a complexidade de layout de arquivos em PDF de duas colunas, com imagens, cabeçalhos de página e notas de rodapé.

* **O Problema dos Extratores Tradicionais:** Leitores de PDF lineares tradicionais apenas extraem os caracteres de forma sequencial na página. Se o documento tiver duas colunas, o extrator tradicional lerá a primeira linha da coluna da esquerda e imediatamente a primeira linha da coluna da direita, misturando textos de assuntos diferentes e destruindo o contexto semântico.

* **A Solução por Visão Computacional do Docling:** O Docling (desenvolvido pela IBM) utiliza modelos de aprendizado profundo (Deep Learning) baseados em visão computacional para "enxergar" a página do documento como uma imagem. Ele detecta as coordenadas das caixas de texto (bounding boxes) e a ordem de leitura correta, permitindo reconstruir o fluxo de leitura lógico de colunas e parágrafos.

* **Extração de Tabelas Complexas:** Um dos maiores trunfos do Docling é a leitura de tabelas de dados clínicos. Ele reconhece a grade de linhas e colunas (mesmo que as linhas divisórias sejam invisíveis no PDF) e reconstrói a tabela estruturada em formato Markdown (com colunas separadas por barras verticais e alinhamentos). Isso permite que a IA faça buscas matemáticas exatas em tabelas de dosagens e parâmetros.

* **Por que o Markdown é o "Combustível" Ideal para o Gemini?** O modelo Gemini 2.5 Flash lê e compreende o formato Markdown com extrema naturalidade. Ao contrário do texto sem formatação, o Markdown sinaliza claramente para a IA a hierarquia das informações:

- O que é um título principal (mapeado pelo Docling com `#`).
- O que é um subtópico importante (`##` ou `###`).
- O que é um item de lista estruturado (`-` ou `\*`).
- O que é um dado de tabela.

Essa estruturação rica em Markdown é o que permite ao Tutor construir resumos impecáveis e simulados com alto rigor técnico.

B. A Estratégia Híbrida de Ingestão (Docling + pypdf)

Embora o Docling seja extremamente inteligente na conversão visual, a execução local de seus modelos neurais consome muito processamento de CPU e memória RAM.

Ao tentar ingerir manuais inteiros de enfermagem com milhares de páginas (como o *Brunner & Suddarth*), o servidor sofria com travamentos de falta de memória RAM. Para solucionar este problema de engenharia, implementamos uma **arquitetura híbrida de roteamento**:

1. **Para Livros e Manuais Extensos (Roteamento pypdf):** Arquivos em formato `.pdf` são roteados diretamente para o `pypdf`, um leitor leve escrito em Python puro. Ele lê o texto de forma sequencial página a página sem carregar modelos de imagem na RAM, processando 1.000 páginas em menos de 1 minuto com estabilidade de 100%.

1. **Para Slides e Protocolos Médicos (Roteamento Docling):** Arquivos em formato `.docx` e `.pptx` são enviados para o `Docling`. Como esses arquivos costumam ser menores e possuem tabelas importantes ou layouts de slides que se perderiam na leitura sequencial, o Docling extrai toda a sua riqueza de layout estruturado de forma perfeita.

C. Divisão Inteligente de Texto (Chunking Semântico)

A quebra do texto bruto em blocos menores segue regras estritas para evitar perda de contexto:

- * O tamanho alvo de cada bloco é de 1200 caracteres (cerca de 180 palavras).

- * O algoritmo não corta o texto no limite exato de caracteres. Ele busca marcas de pontuação final (como pontos finais ou quebras de parágrafo) próximas ao limite. Isso impede que frases explicativas ou diagnósticos clínicos tenham seu sentido cortado pela metade.

D. Deduplicação Inteligente

Para economizar processamento e tempo, o sistema calcula uma assinatura digital única (hash SHA-256) para cada bloco de texto. Antes de enviar o bloco para a inteligência artificial, o banco de dados é consultado. Se a assinatura já existir, o bloco é pulado. Isso permite sincronizar novos arquivos do Google Drive em poucos segundos.

E. Busca por Significado Semântico

Quando um aluno faz uma pergunta no chat:

1. A pergunta é convertida em um vetor de coordenadas que representa o seu significado conceitual.

1. O banco de dados do Supabase calcula a **similaridade de cosseno** entre a pergunta do aluno e os milhares de blocos armazenados. Termos médicos parecidos (como *"hipotensão"* e *"pressão baixa"*) são identificados como equivalentes pela proximidade dos seus conceitos.

1. **Indexação de Alta Velocidade (HNSW):** O banco de dados organiza os blocos em um grafo de atalhos. Isso permite encontrar os blocos de texto mais relevantes em menos de 15 milissegundos, sem precisar ler todo o banco de dados a cada mensagem.

1. O sistema seleciona os **5 trechos** mais similares que atinjam o limite de relevância configurado. Trechos fora do contexto são descartados.

5. Algoritmo de Decisão do Chat (Corrective RAG - CRAG)

Toda mensagem enviada pelo estudante passa por um processo de avaliação antes de receber resposta:

1. **Triagem de Saudação:** Se a mensagem for um simples cumprimento ou solicitação de menu, a resposta padrão do menu é enviada imediatamente, economizando tempo e processamento do servidor.
1. **Busca Vetorial:** Se for uma dúvida conceitual, o sistema faz a busca no Supabase e recupera os 5 trechos mais parecidos.
1. **Avaliador de Relevância (Grader):** O Gemini avalia os 5 trechos individualmente, marcando cada um como relevante ou irrelevante para a dúvida do aluno.
1. **Geração Socrática (Se houver dados):** Se houver trechos relevantes na base de dados, a IA formula a resposta técnica baseando-se estritamente neles, inserindo as referências de origem, um exemplo clínico prático e finalizando com uma pergunta socrática para o aluno responder.
1. **Bloqueio e Fallback (Se não houver dados):** Se nenhum trecho for considerado relevante (ou se a pergunta for de outro assunto), a IA **bloqueia** a geração de texto livre. Ela exibe estritamente a mensagem padrão de recusa, indicando que a base não tem dados suficientes com precisão acadêmica e direciona o aluno para os professores e bases científicas (como PubMed e COFEN). Isso impede que a IA invente procedimentos ou protocolos médicos.
1. **Histórico:** A pergunta e a resposta são salvas no banco para manter o contexto da conversa ativo.

6. Otimizações para Dispositivos Móveis e Responsividade

Para garantir que os estudantes possam utilizar o Tutor confortavelmente em seus smartphones durante as aulas práticas ou estágios hospitalares, aplicamos as seguintes soluções de interface:

- * **Prevenção de Zoom Automático no iOS:** O navegador Safari em iPhones força um zoom visual na tela sempre que o usuário clica em um campo de texto com letra muito pequena. Ajustamos o tamanho do campo de digitação para o padrão que impede esse zoom automático, mantendo o layout fixo e confortável.
- * **Abertura do Teclado Virtual:** O layout foi projetado de forma dinâmica para que a abertura do teclado do celular empurre o campo de digitação para cima sem esconder as mensagens anteriores da tela.
- * **Margens de Segurança (Safe Areas):** A interface adapta o espaçamento automaticamente no topo e no rodapé para evitar que botões e textos fiquem escondidos sob a câmera frontal ("Notch") ou a barra de gestos inferior do celular.
- * **Modo Escuro Sem Oscilações:** A aplicação do tema escuro é executada antes da página carregar na tela, eliminando aquele incômodo clarão branco ao recarregar o site à noite.
- * **Borda de Contraste no Modo Claro:** Para melhorar a usabilidade sob luz solar ou ambientes muito iluminados (como postos de enfermagem), o menu lateral conta com uma borda física destacada na cor azul royal do projeto.

7. Manutenção e Sincronização

A atualização dos materiais de estudo é simples e automática:

1. Os professores adicionam ou removem arquivos (PDF, Word ou Slides) na pasta compartilhada do Google Drive.
1. O script de sincronização automática compara os arquivos locais com os do Drive.
1. Arquivos deletados no Drive são removidos e arquivos novos são baixados.
1. O script de ingestão é executado e insere apenas os novos blocos no banco de dados do Supabase, mantendo a base atualizada em segundos.